第2讲 大数据处理架构Hadoop

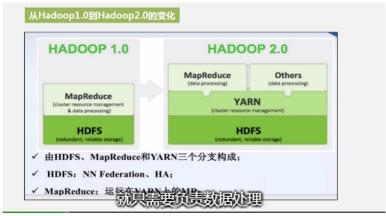
2020年2月25日 11:35

- 1.Hadoop的发展历程
- 2.Hadoop生态系统的各个组件及其功能
- 3.Hadoop的安装和使用方法
- 4.Hadoop集群的部署和使用方法

Hadoop是Apache软件基金会旗下开源软件,是一个开源分布式计算平台 屏蔽了底层实现细节。

Hadoop可以支持多种编程语音





2.0后:

YARN框架做什么事情: 做整个集群的**资源调度**管理, 支持其他计算框架

MapReduce: 只做数据处理

Storm做流计算可以在YARN上做资源调度

Spark批处理

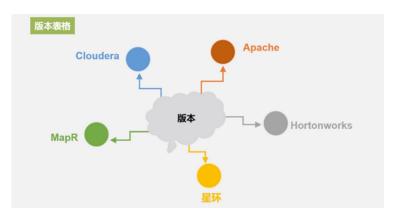
HDFS1.0缺陷:可拓展性很差,只有一个名称节点; 2.0后出现NN Federation (namenode 名称节点)多个名称节点,设置分区管理,构成一个联邦,又引入了HA (high avalability)高可用性,避免单点实效情况,热备份。

Hadoop发行版:

Hortonworks企业版、CDH (Cloudera Distribution Hadoop) 、MapR企业版

选择Hadoop版本的考虑因素:

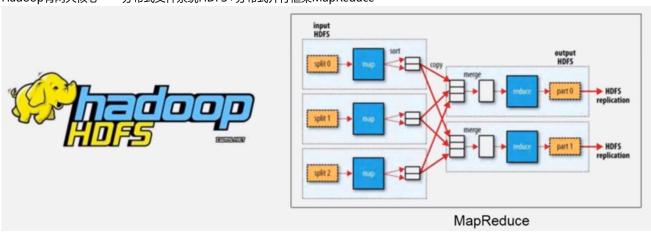
- 1.是否开源 (即是否免费)
- 2.是否有稳定版
- 3.是否经实践检验
- 4.是否有强大的社区支持



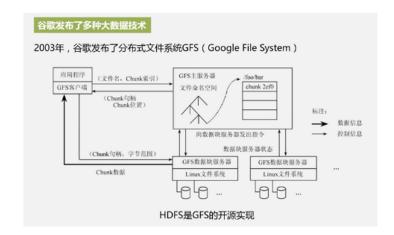


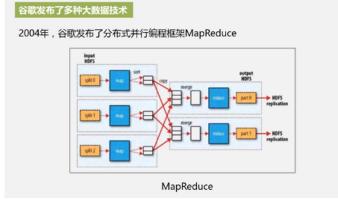


Hadoop有两大核心——分布式文件系统HDFS+分布式并行框架MapReduce

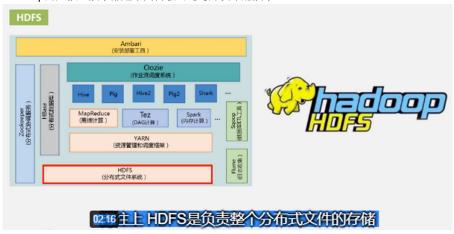


HDFS——>集群分布式存储(海量数据存储) MapReduce——>集群分布式处理(海量数据的处理)





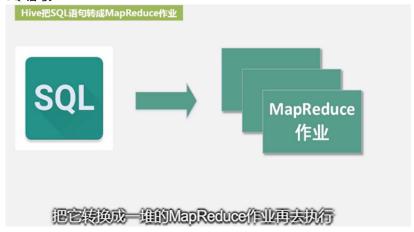
Hadoop两大核心技术都是来自谷歌公司对外发布的技术



MapReduce不是做实时计算,是做离线的批处理

Tez会把很多的MapReduce会把很多的MapReduce作业进行分析优化,构建成有向无环图、Spark也是用Reduce进行处理,基于内存的计算,MapReduce基于磁盘。所以Spark的性能要比MapReduce高一个数量级。

Hive 数据仓库,专门用于企业决策分析。: 可以判断历史十二个月销量走势,OLAP分析,支持SQL语句。



Pig实现流数据处理,轻量级分析,提供类似SQL的查询语言 Pig Latin Oozie 作业流调度系统,工作管理系统。

Zookeeper 分布式协调服务,提供分布式协调一致性服务,也可做分布式锁,集群管理。

Hbase 列族数据库,Hadoop上的非关系型的分布式数据库。

Flume 流数据收集 如美团、淘宝

Sqoop 完成数据导入导出、用于在Hadoop与传统数据库之间进行数据传递,关系型数据库到HDFS、HBase、Hive互导。



Ambari 部署工具,Hadoop快速部署工具、支持Apache Hadoop集群的供应、管理和监控

CentOS 重量级 Ubuntu 相对轻量级

Hadoop 基本安转配置主要包括以下几个步骤:

- 01.创建hadoop用户
- 02.SSH登录权限设置
- 03.安装java环境
- 04.单机安装配置
- 05.伪分布式安装配置

创建hadoop用户

如果安装 Ubuntu 的时候不是用的 "hadoop" 用户,那么需要增加一个名为 hadoop 的用户首先按 ctrl+alt+t 打开终端窗口,输入如下命令创建新用户

\$ sudo useradd -m hadoop -s /bin/bash

上面这条命令创建了可以登陆的 hadoop 用户,并使用 /bin/bash 作为 shell

接着使用如下命令设置密码,可简单设置为 hadoop,按提示输入两次密码

\$ sudo passwd hadoop

可为 hadoop 用户增加管理员权限,方便部署,避免一些对新手来说比较棘手的权限问题

\$ sudo adduser hadoop sudo

SSH登录权限设置

SSH是什么?

- ●SSH 为 Secure Shell 的缩写,是建立在应用层和传输 层基础上的安全协议。SSH 是目前较可靠、专为远程 登录会话和其他网络服务提供安全性的协议。
- ●SSH是由客户端和服务端的软件组成,服务端是一个 守护进程(daemon),它在后台运行并响应来自客户端 的连接请求,客户端包含ssh程序以及像scp(远程拷 贝)、slogin(远程登陆)、sftp(安全文件传输) 等其他的应用程序

配置SSH的原因

Hadoop名称节点(NameNode)需要启动集 群中所有机器的Hadoop守护进程,这个过 程需要通过SSH登录来实现。Hadoop并没 有提供SSH输入密码登录的形式,因此, 为了能够顺利登录每台机器,需要将所有 机器配置为名称节点可以无密码登录它们

无密码登录方式

```
| 修改配置文件 core-site.xml
| <configuration>
| <property>
| <a href="mailto:configuration">
| <property>
| <a href="mailto:configuration">
| <property>
| <a href="mailto:configuration">
| <a href="mailto:configur
```

不设置的话,hadoop系统一退出,会把临时的目录都清除掉 Hdfs://localhost:9000 去访问分布式文件系统的时候用这个路径去访问



关于三种Shell命令方式的区别:

hadoop fs 适用于任何不同的文件系统,比如本地文件系统和HDFS文件系统 hadoop dfs 只能是用于HDFS文件系统

hdfs dfs 跟 hadoop dfs的命令作用一样,也只能适用于HDFS文件系统

2.4Hadoop集群的部署和使用

集群硬件配置:

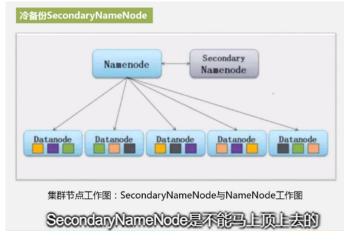
01 NameNode ----- 02 DateNode

MapReduce两大核心组件

-Jobtracker: 负责对整个作业进行管理,把大作业分成小作业,协调分布。 -TaskTracker: 部署在不同的机器上,跟踪和执行分配给自己的小作业

TaskTracker和DataNode可以部署在一台机子上,这个机器既是DataNode同时也是TaskTrackerHDFS:

冷备份 SecondaryNameNode



热备份定义: 一旦NameNode出问题 马上顶上来





NameNode内存设置为16GB到72GB,内存进行通道优化 两个四核或八核CPU ,万兆带宽

Hadoop集群基准测试

- 1.Hadoop自带有一些基准测试程序,被打包在测试程序JAR文件中
- 2.用TestDFSIO基准测试,来测试HDFS的性能
- 3.用排序测试MapReduce: Hadoop自带一个部分排序的程序,这个测试过程的整个数据集都会通过洗牌(Shuffle)传输至Reducer,可以充分测试MapReduce的性能

在云计算环境中使用Hadoop:

百度云、阿里云、亚马云